Proyecto Integrador

Avance 1 EDA - M1

Análisis Exploratorio de Datos de Mercado de Restaurantes en EE. UU.

¿Qué errores e información faltante está presentado en la base de datos?

Herramientas:

Python, Jupyter Notebook, Git, Github , Pandas, Numpy, VSC

Como ejecutarlo:

Usa el Visual Studio Code, ejecuta cada linea/casilla de codigo, leyendo cada markdown donde se explica con mayor detalle que se hizo en cada paso

Hallazgos

Se realizó la carga y exploración del archivo Base_Datos_Restaurantes_USA_v2.csv.

Se filtraron y analizaron los datos correspondientes a la ciudad de **Boston**, donde se identificaron 2.547 registros y 17 columnas. Se encontraron valores faltantes en las siguientes columnas: edad, promedio de gasto en comida, preferencias alimenticias, teléfono y correo electrónico.

No se detectaron filas completamente duplicadas. Se identificaron cinco registros con edad de -5 años y nueve registros con edades superiores a 100 años. Además, se identificaron 123 registros con frecuencia de visita negativa.

Para la tabulación se usaron las columnas de preferencias alimenticias, consumo de licor, género y estatus socioeconómico, y se obtuvo lo siguiente:

- **Preferencias alimenticias:** la categoría más frecuente fue vegetariano, seguida de carnes y mariscos, además de 102 registros sin datos.
- **Consumo de licor:** se registraron 1.612 respuestas afirmativas y 935 negativas.
- **Género:** se identificaron 1.309 mujeres y 1.238 hombres, para un total de 2.547 registros.
- **Estatus socioeconómico:** se observaron cuatro categorías: alto, medio, muy alto y bajo.

Conclusión

El análisis permitió explorar la muestra de clientes de Boston, identificar valores faltantes e inconsistencias, y describir la distribución de variables como género, preferencias alimenticias, consumo de licor y estatus socioeconómico. Es importante aclarar que solo se identificaron los problemas, sin modificar los datos, en cumplimiento del objetivo planteado.

Avance 2 YELP API - M1

Integración de datos de negocios gastronómicos mediante Yelp Fusion API

Objetivo:

Obtener información de negocios gastronómicos de Boston mediante Yelp Fusion API, con el propósito de complementar el análisis exploratorio de datos realizado en el Avance M1 y relacionar la oferta gastronómica con las preferencias alimenticias de los clientes.

Herramientas

Python, Jupyter Notebook, Visual Studio Code (VSC), Pandas, NumPy, Requests y Yelp Fusion API.

Como ejecutarlo

Utilizar Visual Studio Code para abrir el notebook Avance 2 API Yelp.ipynb.

Ejecutar las celdas en orden, leyendo las explicaciones en Markdown que describen cada procedimiento.

Para ejecutar las consultas a Yelp Fusion API se requiere una clave de autenticación válida. Esta debe configurarse de manera segura y no publicarse en el repositorio.

Desarrollo

Se realizó la conexión con Yelp Fusion API mediante el servicio REST, utilizando el endpoint de búsqueda de negocios (/v3/businesses/search).

Se configuraron los parámetros de búsqueda para consultar establecimientos gastronómicos en Boston, utilizando el término restaurants.

Debido a que la consulta permite recuperar hasta 50 negocios por solicitud y existe una limitación en la paginación, se realizaron cuatro consultas para obtener un total de 200 negocios.

La información obtenida se procesó mediante Pandas y se organizó en un DataFrame para facilitar su exploración y análisis.
Información extraída

Se obtuvieron los siguientes campos de los negocios:

- Identificador del negocio.
- Nombre del establecimiento.
- Categorías gastronómicas.
- Calificación en Yelp.
- Número de reseñas.

- Nivel de precios, cuando estaba disponible.

Se verificó que los 200 registros obtenidos correspondieran a 200 identificadores de negocio diferentes.
Hallazgos

Durante la exploración de los datos se identificaron 97 categorías gastronómicas diferentes.

Entre las categorías con mayor número de apariciones se encontraron:

- Cocktail Bars: 85.
- Italian: 60.
- Seafood: 59.
- New American: 41.
- Bars: 39.
- Sandwiches: 39.
- Breakfast & Brunch: 34.
- Wine Bars: 31.

En cuanto a la información de precios, se encontraron 133 registros con información disponible y 67 registros sin información en este campo.
Integración con el Avance M1

Se utilizaron los resultados del análisis exploratorio de clientes de Boston realizado en el Avance M1, que contaba con 2.547 registros.

Se relacionaron las preferencias alimenticias declaradas por los clientes con las categorías gastronómicas obtenidas mediante Yelp Fusion API.

La comparación exploratoria permitió identificar los siguientes resultados:

Preferencia alimenticia	Clientes	Negocios relacionados
Vegetariano	708	1
Vegano	239	0
Carnes	535	24
Mariscos	493	29
Pescado	272	41

Se construyó una tabla consolidada con el nombre del negocio, sus categorías, calificación, número de reseñas y las preferencias alimenticias de los clientes relacionadas con cada establecimiento.
Conclusión

La conexión con Yelp Fusion API permitió complementar la información obtenida en el primer avance mediante la extracción de datos externos de 200 negocios gastronómicos de Boston.

La integración permitió relacionar las preferencias alimenticias de los clientes con las categorías de los establecimientos encontrados, identificando coincidencias entre la demanda declarada por los clientes y la oferta gastronómica disponible en la muestra consultada.

Se identificó una mayor cantidad de negocios relacionados con las categorías de pescado, mariscos y carnes, mientras que las categorías vegetariana y vegana tuvieron una presencia limitada dentro de los 200 negocios analizados.

Es importante aclarar que los resultados corresponden a una muestra de negocios obtenida mediante Yelp Fusion API y no representan la totalidad de establecimientos de Boston. Asimismo, la relación entre las preferencias de los clientes y las categorías de los restaurantes es exploratoria, ya que no se cuenta con información individual que permita determinar qué establecimientos visitan realmente los clientes.

Este avance permitió ampliar el análisis exploratorio inicial mediante la incorporación de una fuente externa de información y la integración de datos de clientes y negocios gastronómicos.

Avance 3 Analisis de datos integrados - M1

Análisis exploratorio de datos (integrado en el avance 1)

1. **Objetivo**

Profundizar en el análisis de los clientes de restaurantes en Estados Unidos, identificando patrones relacionados con sus características demográficas, preferencias alimenticias, comportamiento de consumo, ingresos y membresías premium.

Se utilizaron Python, Pandas, Matplotlib y Seaborn para realizar agrupaciones, cálculos estadísticos y visualizaciones.

2. Ejecución

- Python
- Visual Studio Code o Jupyter Notebook.
- Librerías: Pandas, NumPy, Matplotlib, Seaborn y Openpyxl.

2.1 Clonar el repositorio

git clone:

https://github.com/duvanfelipeovalle-star/ProyectoM1_Duvan_Felipe_Ovalle_dspt13

Ingresar a la carpeta del proyecto:

cd ProyectoM1_Duvan_Felipe_Ovalle_dspt13

2.2 Instalar las dependencias

pip install pandas numpy matplotlib seaborn openpyxl jupyter

2.3 Ubicar los archivos

Verificar que se encuentren disponibles:

Base_Datos_Restaurantes_USA_v2.csv

Avance_1_EDA.ipynb (Dentro de este esta el avance 3)

El archivo CSV debe estar en la ruta indicada en el código de carga de datos del notebook.

2.4. Ejecutar el notebook

Abrir el archivo Avance_1_EDA.ipynb desde Jupyter Notebook o Visual Studio Code.

Ejecutar las celdas en orden, desde la primera hasta la última, utilizando la opción Run All o ejecutándolas individualmente.

Importante: verificar que la ruta del archivo CSV corresponda a su ubicación local antes de ejecutar el notebook.

3. Desarrollo del análisis

3.1 Cantidad de personas por ciudad

Se identificó la distribución de los 30.000 clientes entre las diez ciudades.

- Chicago: 5.384 personas.
- NYC: 4.769 personas.
- Boston: 2.547 personas.
- Phoenix: 1.511 personas.

3.2 Distribución por estrato socioeconómico

Los estratos con mayor representación fueron:
- Medio: 9.325 personas.
- Alto: 9.038 personas.
- Bajo: 6.161 personas.
- Muy Alto: 5.476 personas.

3.3 Gasto promedio por ciudad

Se identificaron diferencias en el gasto promedio registrado:

- Miami: 39,82.
- NYC: 37,13.
- Seattle: 36,86.
- Boston: 29,49.
- Chicago: 25,53.

3.4 Frecuencia de visita y gasto según estrato

Se analizaron 28.318 registros válidos, identificando una tendencia creciente entre el estrato socioeconómico, la frecuencia de visita y el gasto promedio.

El estrato muy alto presentó los mayores valores: frecuencia de 7,48 y gasto promedio de 64,18.

3.5 Relación entre ingresos y gasto promedio

Se analizaron 29.855 registros y se obtuvo una correlación de Pearson de 0,6367, evidenciando una asociación positiva moderada entre los ingresos mensuales y el gasto promedio en comida.

3.6 Preferencias alimenticias por ciudad

Se compararon las preferencias de los clientes en las diez ciudades.

Las categorías más frecuentes fueron:
- Carnes: 7.916 personas.
- Vegetariano: 6.580.
- Mariscos: 5.212.
- Vegano: 3.267.

Chicago presentó la mayor cantidad de clientes con preferencia por carnes, mientras que Miami lideró en mariscos.

3.7 Perfil de clientes de mayor gasto

Se seleccionó el 25 % de clientes con mayor gasto, utilizando un umbral de 44,40. El grupo estuvo compuesto por 7.465 personas.

- Preferencia predominante: carnes (1.881 personas).

- Gasto promedio: 69,88.
- Mediana de gasto: 63,15.
- Gasto máximo: 149,97.

3.8 Membresías premium por ciudad

Se identificó que Chicago tiene la mayor cantidad de afiliados, con 2.215 personas. Sin embargo, Miami presentó el mayor porcentaje de afiliación, con 53,17 %, frente al 36,53 % de Houston.

3.9 Edad y consumo de licor

Se compararon 29.692 registros válidos mediante un diagrama de cajas.
- Personas que no consumen licor: mediana de 52 años.
- Personas que consumen licor: mediana de 46 años.

Se identificaron diferencias en la distribución de edades entre ambos grupos.

Conclusiones generales

El análisis permitió identificar diferencias en el comportamiento de los clientes según ciudad, estrato socioeconómico, ingresos y preferencias alimenticias.

Se destacan Miami por su gasto promedio y porcentaje de membresías premium, Chicago por su concentración de clientes y una asociación positiva moderada entre ingresos y gasto en comida.

Estos resultados proporcionan información útil para identificar oportunidades comerciales y orientar futuras estrategias gastronómicas.